

BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

DISEÑO LÓGICO DE UNA BASE DE DATOS EN EL MODELO RELACIONAL

1. INTRODUCCIÓN.

Los modelos de datos son instrumentos (objetos y reglas) que nos ayudan a representar el UD. El proceso de diseño de una base de datos consiste en representar un determinado UD mediante los objetos que proporciona el modelo de datos (estructuras) aplicando para ello las reglas de dicho modelo (restricciones inherentes).

La información que contendrá una base de datos puede representarse mediante el conjunto de objetos (estructuras), dominios (atributos), relaciones, y el conjunto de reglas de integridad (Restricciones).

Cuando realizamos un diseño en el modelo relacional, existen diferentes alternativas, pudiendo obtener diferentes esquemas relacionales, no todos ellos serán equivalentes, y unos representarán mejor la información que otros.

Por ello conviene profundizar sobre las propiedades que debe tener un esquema relacional para representar adecuadamente la realidad y sobre cuáles son los problemas que pueden derivar de un diseño inadecuado.

En el modelo relacional el diseño puede realizarse de dos formas:

- a) Obtener el modelo relacional (directamente) tras la simple observación del Universo Discurso.
- b) Realizar el análisis y diseño del modelo E/R, y tras su posterior transformación, obtener el modelo relacional.

Las relaciones obtenidas pueden presentar los siguientes problemas:

- Redundancia en la información.
- Inconsistencias (incoherencias) en la información.
- Aparición en la base de datos de estados no válidos en el mundo real. (Anomalías en modificación, inserción, borrado).
- Incapacidad para representar ciertos hechos (Pérdida de información).
- Ambigüedades en el acceso a los datos.
- Pérdida de dependencias entre los datos.
- Existencia de valores nulos.



BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

Veamos un ejemplo:

ESCRIBE. Clave de la relación (Autor, Cod libro)

Autor	Cod_Libro	Nacionalidad	Título	Editorial	Año
Juan	1	Española	BD Relacional	Rama	2002
Juan	2	Española	BD Jerárquica	Anaya	2003
Pedro	2	Española	BD Jerárquica	Anaya	2003

En la relación anterior se presentan varios problemas:

- ◆ Gran cantidad de redundancia → La nacionalidad del autor se repite en cada ocurrencia del mismo. Cuando un libro tiene más de un autor la editorial y el año se repiten también.
- Aparición de estados no válidos:
 - Anomalías de modificación → Puede ocurrir que se modifique el nombre de editorial en una fila sin modificarla en el resto de filas que correspondan al mismo libro.
 - Anomalías de inserción → No sería posible la inserción de un autor del que no hubiera ningún libro (cod_libro → Clave primaria), tampoco podría haber obras anónimas. La inserción de un libro con más de un autor obligaría a la repetición de tuplas.
 - Anomalías de borrado → Si se quiere dar de baja un libro también se perdería información de los autores y viceversa, si se desea borrar un autor desaparecería de la base de datos los libros que ha escrito (a no ser que tuviera más de un autor).

Esto es debido muchas veces a que se falla en un principio básico de diseño: "Hechos distintos se deben almacenar en objetos distintos". Si se hubiera seguido la metodología de diseño de temas anteriores, no se habría presentado una relación de este tipo. La realización de un modelo conceptual el Entidad/Relación y la transformación al Modelo Relacional evita estos problemas. (Aplicación de restricciones de usuario).

El ejemplo anterior incita a descomponer el esquema original en varios esquemas con menos atributos, pero hay que hacerlo con cuidado de no provocar pérdidas de información.

Autor

Autor	Nacionalidad	
Juan	Española	
Pedro	Española	

Libro

Cod_Libro	Título	Editorial	Año
1	BD Relacional	Rama	1992
2	BD Jerárquica	Anaya	1993

En este ejemplo de descomposición se produce pérdida de información, dado que no se podrían encontrar los libros escritos por Juan.



BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

2. LA TEORÍA DE LA NORMALIZACIÓN

Necesidad de normalizar: ante cualquier duda de si el modelo relacional es correcto, es preferible aplicar un método formal de análisis, la Teoría de la Normalización. Teóricamente están unidos el Modelo Relacional y la Normalización.

OBJETIVO: Consiste en la descomposición sin pérdida de información, ni de semántica de la relación universal (o de una colección de relaciones equivalentes a la misma), en una colección de relaciones en la que las anomalías de actualización (Inserción, borrado y modificación) no existan o sean las mínimas.

El objetivo fundamental es eliminar redundancias, para que sea mínima o incluso nula, para así eliminar las anomalías de actualización.

Aproximación por descomposición.

- a) Relación universal. (Todos los atributos). La aproximación por descomposición para concebir esquemas relacionales parte de una relación compuesta de todos los atributos, llamada la Relación Universal, para descomponer después esta relación en sub-relaciones que no padecen las anomalías anteriormente descritas.
- b) Proceso de depuración (Sucesiva). El proceso es un proceso de depuración sucesiva que debe lograr aislar unas entidades y unas asociaciones del mundo real. Debe estar realizado por un algoritmo a partir de una buena comprensión semántica de los datos.

En este proceso de descomposición intervienen dos operaciones sobre relaciones:

- **Proyección**: para eliminar algunos atributos y eliminar tuplas repetidas.
- Reunión natural (Join): para concatenar tuplas de varias de relaciones.

La descomposición supone sustituir la relación R(A1 ... An) en una serie de relaciones R1 ... Rn de manera que la reunión (Join) de R1 hasta Rn permite obtener el mismo esquema que la relación R original. Y será sin perdida, si además se cumple que para toda extensión de R se cumple que es igual a la extensión de la reunión (R1 .. Rn).



BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

FORMAS NORMALES.

La teoría de normalización se centra en (FN) Formas normales, persiguiendo que los esquemas relacionales cumplan unas determinadas condiciones. Se dice que un esquema de relación está en una determinada forma normal si satisface un conjunto determinado de restricciones.

1FN, 2FN y 3FN → Codd (Restricciones y normas)

FNBC Boyce y Codd. Redefinición de 3FN.

4FN y 5FN → Fagin.

Todas se basan en: "Los datos son independientes de las aplicaciones (software) que los utilizan".

Relación entre formas normales.

Una relación está en 5FN si también lo está en todas las anteriores.

Una relación que está en 1FN no tiene por qué estar en 2FN.

El objetivo es normalizar hasta obtener la máxima forma normal posible (al menos hasta la FN de Boyce-Codd).

Enfoque Dependencias.

Dependencias Funcionales → 2FN, 3FN, FNBC

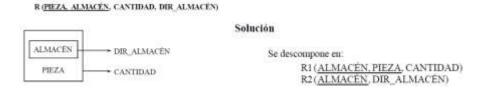
Dependencias Multivaluadas → 4FN

Dependencias de Proyección/Combinación (Join) → 5FN

Normalización. Enfoque intuitivo inicial.

1FN → Codd. Restricción inherente del modelo relacional. En una relación no puede haber grupos repetitivos.

2FN → Una relación está en 2FN si además de estar en 1FN todos los atributos (secundarios) que no forman parte de ninguna clave candidata suministran información acerca de la clave completa. Ejemplo:





BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

3. DEPENDENCIAS.

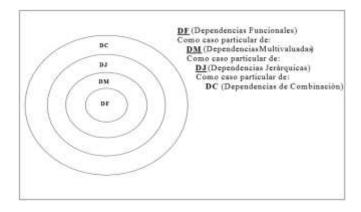
- Las dependencias son propiedades inherentes a los propios datos, al contenido semántico de los datos. Pueden ser restricciones propias de usuario.
- Son invariantes en el tiempo, es decir, se han de cumplir para cualquier extensión del esquema de relación, aunque no se puedan deducir en todas.
- Las dependencias son restricciones de integridad que muestran las interrelaciones existentes entre los atributos del mundo real, cuya semántica tratamos de incorporar a nuestra base de datos.
- Existen otras restricciones de integridad que no se pueden expresar por medio de dependencias.

Puesto que las dependencias constituyen una parte importante de la semántica de nuestro UD, deben ser incluidas en los esquemas de relación. De modo que un esquema de relación será un par <*A*, *DEP*>, donde:

 $A \rightarrow$ Conjunto de atributos de la relación.

DEP → Conjunto de dependencias existentes entre dichos atributos.

Existen distintos tipos de dependencias, Las tres primeras formas normales se basan en el concepto de Dependencia Funcional. En el proceso de normalización será fundamental identificar todas las dependencias funcionales del universo del discurso cuyo diseño estamos realizando y procuraremos conservar dichas dependencias a lo largo de todo el proceso.



Distintos tipos de dependencias

Cada tipo de dependencia es un caso particular del grupo que le sigue.

BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

4. DEFINICIÓN DE DESCRIPTOR

Dada la relación

Se dice que X es un descriptor de R, si

$$X \subseteq (A1, A2, \dots, An)$$

5. DESCRIPTORES EQUIVALENTES

Sean X e Y, son dos descriptores de R, si se cumple que:

$$X \longrightarrow X$$

entonces X e Y son EQUIVALENTES.

$$X \longleftrightarrow Y$$

6. DEPENDENCIA FUNCIONAL (DF)

Sea la relación

sean:

$$X \subseteq (A1, A2, ..., An)$$

 $Y \subseteq (A1, A2, ..., An)$

dos descriptores de R.

Se dice que Y depende funcionalmente de X si a cada valor de X le corresponde un único valor de Y.

7. DEPENDENCIA FUNCIONAL TOTAL O COMPLETA (DFT)

Sea la DF:
$$X \longrightarrow Y$$

Si el descriptor X es compuesto:

Y tiene dependencia funcional completa respecto de X si:

$$\begin{cases} X1 & \longleftarrow & Y \\ X2 & \longleftarrow & Y \end{cases}$$

$$x \rightarrow y$$



BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

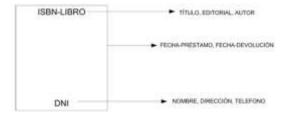
Ejercicio:



8. GRAFO O DIAGRAMA DE DEPENDENCIAS FUNCIONALES (DDF)

Es una herramienta de ayuda en el proceso de normalización de un esquema relacional. Permite representar gráficamente el conjunto de atributos y las dependencias funcionales elementales existentes entre ellos.

- En una caja se incluyen los atributos que forman la clave principal.
- Una flecha por cada dependencia funcional no trivial.



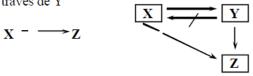
9. DEPENDENCIA FUNCIONAL TRANSITIVA

Dada la relación

en la que existen las siguientes dependencias funcionales:

$$X \longrightarrow Y$$
 $Y \longrightarrow Z$
 $Y \longrightarrow X$

se dice que Z tiene una dependencia TRANSITIVA respecto a X a través de Y



X, Y, Z no tienen por qué ser disjuntos

Las dependencias funcionales transitivas no se representan en el DDF.



BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

10. ESTUDIO DE DEPENDENCIAS FUNCIONALES

Las dependencias funcionales son restricciones de integridad sobre los datos. Conocer las dependencias funcionales en el momento del diseño de la base de datos permite crear mecanismos para evitar la redundancia (y los potenciales problemas de integridad que eso conlleva) y mejorar la eficiencia.

REGLAS DE DERIVACIÓN

El conocimiento de ciertas Dependencia Funcionales puede llevar a inferir la existencia de otras que no se encontraban en el conjunto inicial.

Dado un esquema de relación: R (A, F) es posible deducir nuevas dependencias funcionales que sean una **CONSECUENCIA LÓGICA** del conjunto de partida F. Las nuevas dependencias f que se cumplen para cualquier extensión de r de R son consecuencia lógica de F (F \mid = f)... F⁺.

El **CIERRE** de un conjunto de Dependencias Funcionales DF (que se denota DF⁺) es el conjunto todas las dependencias que son consecuencia lógica de DF:

DF' = $\{X \rightarrow Y \mid DF \mid = X \rightarrow Y\}$, DF será siempre un subconjunto del cierre (DF \subseteq DF⁺). Por lo tanto, las notaciones R(A, DF) y R(A, DF⁺) definen el mismo esquema de relación.

Sin embargo, las definiciones de consecuencia lógica y de cierre de un conjunto de dependencias funcionales no permiten el cálculo de éste, por lo que se hacen necesarias unas reglas de derivación que faciliten la implicación lógica de dependencias, son los Axiomas de Armstrong.

Dado un conjunto DF de dependencias funcionales, se dice que f se **deriva** de DF, lo que se representa por DF |— f, si f se puede obtener por aplicación sucesiva de los axiomas de Armstrong a DF (o a un subconjunto de DF), es decir, si existe una secuencia de dependencias f1, f2,...fn, tal que fn = f, donde cada fi es bien un elemento de DF o ha sido derivada a partir de las dependencias precedentes aplicando las reglas de derivación.

Aunque son conceptos distintos, se cumple siempre que si una dependencia *f* es una **consecuencia lógica** de un conjunto de dependencias, también será posible **derivarla** de dicho conjunto aplicando los axiomas de Armstrong, y viceversa; es decir:

∀ f | DF |— f implica_que DF |= f (propiedad de corrección), y

∀ f | DF |= f implica_que DF |— f (propiedad de plenitud)

BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

AXIOMAS DE ARMSTRONG

A-1: Reflexividad:

Si
$$Y \subseteq X$$
, entonces $X \longrightarrow Y$

A-2: Transitividad:

Si
$$X \longrightarrow Y e Y \longrightarrow Z$$

entonces $X \longrightarrow Z$

A-3: Aumentatividad:

Si
$$X \longrightarrow Y$$
 y $Z \subseteq W$ entonces $XW \longrightarrow YZ$

Nota: Todo atributo o descriptor, se considera que está incluido en él mismo.

Estos tres axiomas son los básicos, a partir de ellos se pueden deducir otros:

Propiedades o axiomas derivados:

A-4: Proyectividad:

Si
$$X \longrightarrow Y \in Y' \subset Y$$
 entonces $X \longrightarrow Y'$

A-5: Unión o aditividad:

Si
$$X \longrightarrow Y y X \longrightarrow Z$$
 entonces $X \longrightarrow Y Z$

A - 6: Pseudotransitividad:

Si X
$$\longrightarrow$$
 Y e YW \longrightarrow Z entonces XW \longrightarrow Z

EJERCICIO: Demostrar las propiedades o axiomas derivados de Armstrong.

EJERCICIO

Dado el esquema de relación, R(A, B, C, D; A \rightarrow BC, B \rightarrow D). Aplicar los axiomas de Armstrong para obtener que: A \rightarrow ABCD.

BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

EJERCICIO

Dada la relación R ({CE, NE, P, G, CP, C}, DF)

Siendo DF= {CE
$$\rightarrow$$
 NE, NE \rightarrow CE, P \rightarrow CE, G \rightarrow P, (CP, P) \rightarrow G, CE \rightarrow C, P \rightarrow C}

Comprobar si la dependencia $NE \rightarrow C$ se deriva de DF.

11. CONCEPTOS SUPERCLAVE Y CLAVE DE UNA RELACIÓN.

Denominamos **Superclave** k de una relación R(T) a un subconjunto no vacío de T, tal que T tiene dependencia funcional respecto de k,

$$k \subseteq T \land k \neq \phi \land k \longrightarrow T$$

Si no existe ningún subconjunto k' de k, tal que:

k es una clave de R.

$$k \subseteq T \land k \neq \emptyset \land k \longrightarrow T \land (\not\not\equiv k' \land k' \longrightarrow T)$$

En la relación R(T) se denominan atributos **principales** a aquellos que son elementos de alguna clave de R(T).

A los demás atributos se les denomina **no principales**.

EJERCICIO

Dado el esquema de relación: R(A, B, C, D, E; A \rightarrow B, C \rightarrow D, D \rightarrow E)

Calcular y demostrar cual es la clave candidata y las posibles superclaves.

EJERCICIO

Sea R(A, B, C, D, E, F) y DF = {BD \rightarrow E, CD \rightarrow A, E \rightarrow C, B \rightarrow D}. ¿Cuáles son las llaves minimales (Claves)?



BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

12. EQUIVALENCIA DE CONJUNTOS DE DF

Dados dos conjuntos de dependencias:

 $Cod_Curso \rightarrow Cod_Programa$

$$\begin{aligned} DF_1 = \{ & Cod_Curso \rightarrow Nombre, \\ & Nombre \rightarrow Cod_Curso, \\ & Cod_Curso \rightarrow Cod_Departamento, \\ & Cod_Curso \rightarrow Cod_Departamento, \\ & Cod_Curso \rightarrow Cod_Programa \} \end{aligned}$$

$$\begin{aligned} DF_2 = \{ & Cod_Curso \rightarrow Nombre, \\ & Nombre \rightarrow Cod_Curso, \\ & Nombre \rightarrow Cod_Departamento, \\ & Nombre \rightarrow Cod_Programa \} \end{aligned}$$

Al calcular el cierre de Cod_Curso en DF₂ y de Nombre en DF₁, se puede comprobar que todas las dependencias de DF₁ están en DF⁺₂ y las de DF₂ están en DF⁺₁, por lo tanto se puede afirmar que DF₁ y DF₂ son equivalentes. Lo que supone que:

- Tendríamos como resultado dos claves candidatas (k).
- Habría que elegir una de ellas. (Se desprecian las DF de la no elegida)
- En el Diagrama de DF no se representarían las DF de la clave secundaria.

EJERCICIO

Se considera la tabla relacional R(A,B,C,D,E; DF) con las siguientes dependencias funcionales:

DF={		Se pide:
$A\toB$	$B\toA$	Represente gráficamente las dependencias funcionales anteriores.
$A \to C$	$B\toC$	antenores.
$A\toD$	$E\toD$	B. Determine todas las claves candidatas de R.
$A\toE$	$C\toE\}$	C. Determine los campos equivalentes y los campos principales y no principales de la tabla.
		D. ¿Está R en 3FN? Si no lo está, escribe un conjunto de relaciones equivalentes en 3FN

BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

13. FORMAS NORMALES

La forma normal de una relación es un estado de la misma que indica la calidad de su diseño, en cuanto a la redundancia de información evitada. Su definición está basada en las dependencias funcionales, multivaluadas, de join, etc.

PRIMERA FORMA NORMAL (1^a FN)

Una relación R(A, DEP), está en 1FN si todos sus atributos, para cada tupla, tienen un único valor del dominio simple subyacente, es decir, no hay grupos repetitivos de información. Damos por hecho que al menos un esquema relacional está en la 1ª FN.

SEGUNDA FORMA NORMAL (2ª FN)

Una relación R(A, DEP) está en 2ª FN si cumple las siguientes condiciones:

- Está en 1ª FN.
- Cada atributo no principal (secundario) tiene una dependencia funcional completa (total) respecto de la clave (y no de un subconjunto de esta).

EJEMPLO: dada la relación ESTUDIANTE_BECA(A, Dep), donde:

TEOREMA DE DESCOMPOSICIÓN DE DELOBEL-PICHAT (1978)

Si en una relación R(U), existe la dependencia funcional $X \rightarrow Y$ con X no clave, se puede descomponer en dos equivalentes R₁ (X, Y) y R₂(U – Y), que unidas a través de Join permiten obtener el esquema R original.

$$R(U) = R_1(X, Y) \bowtie R_2(U - Y)$$



BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

TERCERA FORMA NORMAL (3ª FN)

Una relación R(A, DEP), está en 3ª FN si cumple las siguientes condiciones:

- Está en 2ª FN.
- Ningún atributo no principal (secundario) tiene una dependencia funcional transitiva respecto de la clave (no existen dependencias entre atributos no principales).

Un modelo de datos relacional en 3ª FN se considera de buena calidad y garantiza un buen equilibrio entre eficiencia y control de redundancia.

EJEMPLO: dada la relación ESTUDIANTE(A, Dep), donde:

```
A= { Cod_Estudiante, Cod_Proyecto, Nombre_Proyecto }

DEP= { Cod_Proyecto → Nombre_Proyecto,

Cod_Estudiante → Cod_Proyecto }
```

FORMA NORMAL DE BOYCE-CODD: FNBC

Suele ocurrir cuando existen claves candidatas que se solapan. Por lo que las relaciones en 3ª FN pueden tener todavía anomalías de actualización. Establece el máximo control de redundancia mediante dependencias funcionales. La idea consiste en que cada atributo dependa sólo de la clave (en su totalidad, no de una parte).

Una relación R(A, DEP), está en FNBC si cumple las siguientes condiciones:

- Está en 3ª FN.
- Toda dependencia funcional debe venir determinada por la clave.

EJEMPLO: dada la relación ASISTE(A, Dep), donde:

```
A= { Cod_Curso, Nom_Curso, Cod_Estudiante, Calificación }

DEP= { Cod_Curso → Nom_Curso, Nom_Curso → Cod_Curso, Cod_Curso, Cod_Estudiante → Calificación}
```



BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

EJEMPLO: dada la relación SE_MATRICULA(A, Dep), donde:

```
A= { Cod_Curso, Cod_Edición, Cod_Estudiante, Fecha }

DEP= { Cod_Curso, Cod_Edición, Cod_Estudiante → Fecha,

Cod_Edición, Cod_Estudiante, Fecha → Cod Curso }
```

EJEMPLO: dada la relación CLASE(A, Dep), donde:

CUARTA FORMA NORMAL (4° FN)

Una relación R(A, DEP), está en 4ª FN si cumple las siguientes condiciones:

- Está en FNBC.
- Las únicas **dependencias multivaluadas** existentes vengan implicadas por la clave.

QUINTA FORMA NORMAL (5° FN)

Una relación R(A, DEP), está en 4ª FN si cumple las siguientes condiciones:

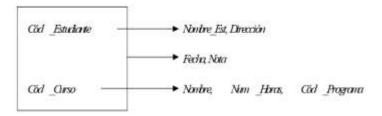
- Está en 4ª FN.
- Las únicas **dependencias de Join** existentes vengan implicadas por la clave.



BASES DE DATOS

TEMA 7: TEORÍA DE LA NORMALIZACIÓN

EJERCICIO-EJEMPLO:



EJERCICIO-EJEMPLO:

PRESTAMO (num_socio, nombre_socio, cod_libro, fecha_prestamo, editorial, país) Claves candidatas: (num_socio, cod_libro), (nombre_socio, cod_libro)

14. BIBLIOGRAFÍA

- ◆ Dolores Cuadra, Elena Castro, Ana Iglesias, Paloma Martínez, Javier Calle, César de Pablo, Harith Al-Jumaily y Lourdes Moreno (2007): Desarrollo de Bases de Datos: casos prácticos desde el análisis a la implementación. RAMA
- Silberschatz, A.; Korth, H.; Sudarshan, S., 2006: Fundamentos de bases de datos. (5ª edición). McGraw-Hill.
- ◆ Diseño de Bases de Datos Relacionales". De Miguel, A.; Piattini, M.; Marcos, E.; Ra-Ma, 1999.
- ◆ Levene, M. y Loizou, G., 1999: A Guided Tour of Relational Databases and Beyond. Springer Verlag.
- ◆ Elmasri, R.; Navathe, S.B.; Sistemas de Bases de Datos: Conceptos fundamentales (2ª edición). Addison-Wesley, 1997.